

Estimación puntual

Estimación

Supongamos que tenemos una muestra aleatoria de una distribución F_θ .

$$X_1, \dots, X_n \sim F_\theta \quad i.i.d.,$$

Interesa conocer *aproximadamente* θ .

Definición. Un *estimador puntual* de θ es una función de la muestra $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$.

Ejemplos

1- Se quiere conocer el peso medio de los paquetes de arroz producido por una fábrica. Para ello , se toman 30 cajas de arroz al azar y se las pesa. Se obtiene:

0.96	0.97	1.12	1.16	1.03	0.95	0.91	0.87	0.96	1.04
0.77	0.99	0.84	1.08	1.12	0.78	0.95	0.93	1.09	0.92
1.00	0.92	1.02	0.90	0.87	0.85	1.03	1.04	0.92	1.07

Suponemos que el peso de un paquete elegido al azar es una variable aleatoria $X \sim \mathcal{N}(\mu, \sigma^2)$.

2- Una fábrica de lámparas sabe que el tiempo de vida, en días, de las lámparas que fabrica, sigue una distribución $Exp(\lambda)$. Obtener una fórmula para estimar λ partir de una muestra aleatoria $X_1 \dots X_n$.

Un estimador es una variable aleatoria

- Antes de probar las lámparas no sabemos cuánto durará cada una. Así, la duración de la primera puede ser considerada una v.a. X_1 , la segunda una v.a. X_2 , etc.
- Cualquier función de la muestra es una v.a. por ejemplo: $\bar{X}, \tilde{X}, S^2, \max(X_1, \dots, X_n)$, etc. Una vez observado el resultado del experimento los valores calculados serán denotados $\bar{x}, \tilde{x}, s^2, \max(x_1, \dots, x_n)$, o $\bar{X}_{obs}, \tilde{X}_{obs}, S^2_{obs}, \max(X_1, \dots, X_n)_{obs}$,

Estimación

- Un buen estimador deberá tener la propiedad de que cualquiera sea el valor de θ , que es desconocido, la diferencia $\hat{\theta} - \theta$ sea pequeña.
- Veremos dos métodos:
 - Método de los momentos
 - Método de máxima verosimilitud

Método de los momentos

- **Definición:** Sea X una v.a. Se denomina momento (poblacional) de orden k o k -ésimo momento de X a $E(X^k)$, si esa esperanza existe.
- **Definición:** Dada una muestra aleatoria X_1, X_2, \dots, X_n , se denomina momento muestral de orden k o k -ésimo momento muestral de $X_1 \dots X_n$ a

$$\frac{\sum_{i=1}^n X_i^k}{n}$$

Método de los momentos

Definición: Sea X_1, X_2, \dots, X_n una m.a. de una distribución con función de distribución F_θ (que depende de un parámetro θ)

- El estimador de momentos de θ basado en el primer momento es el valor $\hat{\theta}$ tal que

$$\frac{\sum_{i=1}^n X_i}{n} = E_{\hat{\theta}}(X)$$

- El estimador de momentos de θ basado en el k-ésimo momento es el valor $\hat{\theta}$ tal que

$$\frac{\sum_{i=1}^n X_i^k}{n} = E_{\hat{\theta}}(X^k)$$

.

donde $E_{\hat{\theta}}(X) = E_{F_{\hat{\theta}}}(X)$.

Motivación: Por **LGN** $\bar{X} \approx E_\theta(X)$ para n grande.

Ejemplo 1: Normal

Se quiero conocer el peso medio de los paquetes de arroz producido por una fábrica. Para ello , se toma una muestra de 30 cajas de arroz y se las pesa. Se obtiene:

0.96	0.97	1.12	1.16	1.03	0.95	0.91	0.87	0.96	1.04
0.77	0.99	0.84	1.08	1.12	0.78	0.95	0.93	1.09	0.92
1.00	0.92	1.02	0.90	0.87	0.85	1.03	1.04	0.92	1.07

Suponemos que el peso de un paquete elegido al azar es una variable aleatoria $X \sim \mathcal{N}(\mu, \sigma^2)$

Al elegir n paquetes tenemos Sea X_1, X_2, \dots, X_n i.i.d.
 $X_i \sim \mathcal{N}(\mu, \sigma^2)$

Estimador de los momentos de μ de orden 1:

$$\frac{1}{n} \sum_{i=1}^n X_i = E_{\hat{\mu}}(X) = \hat{\mu}.$$

Con estos datos la estimación que se obtiene es $\hat{\mu}_{obs} = 0.97$

Ejemplo 2: Exponencial

Una fábrica de lámparas sabe que el tiempo de vida, en días, de las lámparas que fabrica, sigue una distribución $Exp(\theta)$. Obtener una fórmula para estimar θ partir de una muestra aleatoria $X_1 \dots X_n$.

$$X_1, X_2, \dots, X_n \sim Exp(\theta)$$

Ejemplo 2: Exponencial

Una fábrica de lámparas sabe que el tiempo de vida, en días, de las lámparas que fabrica, sigue una distribución $Exp(\theta)$. Obtener una fórmula para estimar θ partir de una muestra aleatoria $X_1 \dots X_n$.

$$X_1, X_2, \dots, X_n \sim Exp(\theta)$$

Para hallar el estimador de momentos de θ , hay que despejar $\hat{\theta}$ de

$$\frac{1}{n} \sum_{i=1}^n X_i = \mathbb{E}_{\hat{\theta}}(X_1)$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{\hat{\theta}} \Rightarrow \hat{\theta} = \frac{1}{\hat{X}}$$

Ejemplo 3: Distribución Uniforme

$$X_1, X_2, \dots, X_n \sim \mathcal{U}(0, \theta).$$

Ejemplo 3: Distribución Uniforme

$$X_1, X_2, \dots, X_n \sim \mathcal{U}(0, \theta).$$

Hay que despejar θ de

$$\frac{1}{n} \sum_{i=1}^n X_i = \mathbb{E}_{\hat{\theta}}(X_1)$$

$$\frac{1}{n} \sum_{i=1}^n X_i = \frac{\hat{\theta}}{2} \Rightarrow \hat{\theta} = \frac{1}{2n} \sum_{i=1}^n X_i.$$

Estimador de los momentos:

Generalización cuando hay varios parámetros

Definición: Sea X_1, X_2, \dots, X_n una m.a. de una distribución que depende de m parámetros $\theta_1, \theta_2, \dots, \theta_m$. Los estimadores de momentos de $\theta_1, \theta_2, \dots, \theta_m$ son los valores $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ que se obtienen igualando m momentos poblacionales con los correspondientes momentos muestrales. En general, se obtienen resolviendo el siguiente sistema de ecuaciones

$$\frac{\sum_{i=1}^n X_i^k}{n} = E(X^k) \quad k = 1, 2, \dots, m$$

Ejemplo 4: Estimación de ambos parámetros de la normal

Supongamos que tenemos una muestra aleatoria

$$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2).$$

Se tiene $\mathbb{E}_{\mu, \sigma^2}(X) = \mu$ y $\mathbb{E}_{\mu, \sigma^2}(X^2) = \mu^2 + \sigma^2$.

Para encontrar el estimador de momentos de μ y σ^2 hay que resolver el sistema

$$\frac{1}{n} \sum_{i=1}^n X_i = \mathbb{E}_{\hat{\mu}, \hat{\sigma}^2}(X_1) = \hat{\mu}$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = \mathbb{E}_{\hat{\mu}, \hat{\sigma}^2}(X_1^2) = \hat{\mu}^2 + \hat{\sigma}^2$$

Ejemplo 3: Estimación de ambos parámetros de la normal

$$\left\{ \begin{array}{l} \frac{1}{n} \sum_{i=1}^n X_i = \hat{\mu} \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \hat{\mu}^2 + \hat{\sigma}^2 \end{array} \right.$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2$$

Máxima verosimilitud

Caso discreto

- Supongamos que tenemos una muestra aleatoria de una distribución discreta F_θ : $X_1, \dots, X_n \sim F_\theta$.
- $\mathbf{x} = x_1, \dots, x_n$ realización de X_1, \dots, X_n i.i.d.
- Función de verosimilitud asociada a $\mathbf{x} = x_1, \dots, x_n$:

$$L(\cdot ; \mathbf{x}) : \Theta \rightarrow \mathbb{R}$$

$$L(\theta ; \mathbf{x}) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n), X_i \sim p(\cdot, \theta) .$$

$$L(\theta ; \mathbf{x}) = \prod_{i=1}^n p(x_i, \theta) ,$$

Nos interesa ver cuán **verosímil** es que un determinado parámetro haya generado los datos.

Máxima verosimilitud

Caso discreto

- Supongamos que tenemos una muestra aleatoria de una distribución discreta F_θ : $X_1, \dots, X_n \sim F_\theta$.
- $\mathbf{x} = x_1, \dots, x_n$ realización de X_1, \dots, X_n i.i.d.
- Función de verosimilitud asociada a $\mathbf{x} = x_1, \dots, x_n$:

$$L(\cdot ; \mathbf{x}) : \Theta \rightarrow \mathbb{R}$$

$$L(\theta ; \mathbf{x}) = \mathbb{P}(X_1 = x_1, \dots, X_n = x_n) , X_i \sim p(\cdot, \theta) .$$

$$L(\theta ; \mathbf{x}) = \prod_{i=1}^n p(x_i, \theta) ,$$

Nos interesa ver cuán **verosímil** es que un determinado parámetro haya generado los datos.

- Propuesta de máxima verosimilitud:

$$\hat{\theta}(\mathbf{x}) = \operatorname{argmax}_{\theta \in \Theta} L(\theta ; \mathbf{x}) .$$

o sea

Máxima Verosimilitud

Caso continuo

- Supongamos que tenemos una muestra aleatoria de una distribución continua F_θ : $X_1, \dots, X_n \sim F_\theta$.
- $\mathbf{x} = x_1, \dots, x_n$ realización correspondiente a X_1, \dots, X_n
- Función de verosimilitud: $L(\cdot ; \mathbf{x}) : \Theta \rightarrow \mathbf{bR}$

$$L(\theta ; \mathbf{x}) = f_{X_1, \dots, X_n}(x_1, \dots, x_n), X_i \sim f(\cdot, \theta).$$

$$L(\theta ; \mathbf{x}) = \prod_{i=1}^n f(x_i, \theta),$$

- Propuesta de Máxima Verosimilitud:

$$\hat{\theta}(\mathbf{x}) = \operatorname{argmax}_{\theta \in \Theta} L(\theta ; \mathbf{x}).$$

o sea $\hat{\theta}_n = h_n(X_1, \dots, X_n)$.

Estimador de Máxima verosimilitud

Caso discreto y continuo

$$X_1, \dots, X_n \sim F_\theta,$$

$$\mathbf{X} = (X_1, \dots, X_n)$$

Estimador de máxima verosimilitud de θ :

$$\hat{\theta} = \hat{\theta}(\mathbf{X}) = \operatorname{argmax}_{\theta \in \Theta} L(\theta ; \mathbf{X}) .$$

Recordar:

- $\hat{\theta}(\mathbf{X})$ es una variable aleatoria
- $\hat{\theta}(\mathbf{X})_{obs} = \hat{\theta}(\mathbf{x})$ es una realización, i.e. un número.

Ejemplo $\mathcal{E}(\lambda)$: $f(x, \lambda) = \lambda e^{-x\lambda} \mathcal{I}_{(0,\infty)}(x)$.

X_1, \dots, X_n v.a. i.i.d. $X_i \sim \mathcal{E}(\lambda), \lambda > 0$

$$L(\lambda; \mathbf{x}) = \prod_{i=1}^n f(x_i, \lambda) = \prod_{i=1}^n \lambda e^{-x_i \lambda} \mathcal{I}_{(0,\infty)}(x_i)$$

- si $x_i > 0 \forall i$

$$L(\lambda; \mathbf{x}) = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$$

- Si consideramos el $\log L$, resulta

$$\ell(\lambda; \mathbf{x}) = n \log(\lambda) - \lambda \sum_{i=1}^n x_i$$

- Derivando e igualando a 0 queda

$$\frac{n}{\lambda} - \sum_{i=1}^n x_i = 0 \Rightarrow \text{punto crítico es } 1/\bar{x}_n, \quad \text{ver que maximiza!}$$

- $\Rightarrow \hat{\lambda} = 1/\bar{X}_n$

$$X_1,\cdots,X_n \text{ v.a. i.i.d. } X_i \sim \mathcal{N}(\mu,9), \, f\left(x,\mu,9\right)=\frac{1}{\sqrt{2\pi}}\,\frac{1}{3}\,e^{-\frac{1}{2}\,\frac{\left(x-\mu\right)^2}{9}}$$

$$L(\mu,9;\mathbf{x}) \quad = \quad \prod_{i=1}^n f(x_i,\mu,9)$$

$$X_1, \cdots, X_n \text{ v.a. i.i.d. } X_i \sim \mathcal{N}(\mu, 9), \, f \left(x, \mu, 9 \right) = \frac{1}{\sqrt{2\pi}} \, \frac{1}{3} \, e^{-\frac{1}{2} \frac{(x-\mu)^2}{9}}$$

$$L(\mu, 9; \mathbf{x}) \quad = \quad \prod_{i=1}^n f(x_i, \mu, 9) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \, \frac{1}{3} \, e^{-\frac{1}{2} \frac{(x_i - \mu)^2}{9}}$$

$$X_1, \cdots, X_n \text{ v.a. i.i.d. } X_i \sim \mathcal{N}(\mu, 9), f(x, \mu, 9) = \frac{1}{\sqrt{2\pi}} \frac{1}{3} e^{-\frac{1}{2} \frac{(x-\mu)^2}{9}}$$

$$L(\mu, 9; \mathbf{x}) = \prod_{i=1}^n f(x_i, \mu, 9) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \frac{1}{3} e^{-\frac{1}{2} \frac{(x_i - \mu)^2}{9}}$$

$$L(\mu, 9; \mathbf{x}) = \left(\frac{1}{\sqrt{2\pi}} \right)^n \left(\frac{1}{3} \right)^n e^{-\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \mu)^2}{9}}$$

X_1, \dots, X_n v.a. i.i.d. $X_i \sim \mathcal{N}(\mu, 9)$, $f(x, \mu, 9) = \frac{1}{\sqrt{2\pi}} \frac{1}{3} e^{-\frac{1}{2} \frac{(x-\mu)^2}{9}}$

$$L(\mu, 9; \mathbf{x}) = \left(\frac{1}{\sqrt{2\pi}} \right)^n \left(\frac{1}{3} \right)^n e^{-\frac{1}{2} \frac{\sum_{i=1}^n (x_i - \mu)^2}{9}}$$

- Tomemos logaritmo

$$\ell(\mu, 9; \mathbf{x}) = cte - \frac{1}{2} \frac{\sum_{i=1}^n (x_i - \mu)^2}{9}$$

Maximizar a $\ell(\mu, 9; \mathbf{x})$ como función de μ equivale a minimizar

$$h(\mu) = \sum_{i=1}^n (x_i - \mu)^2$$

Un par de clases atrás, vimos que $h(\mu)$ se minimiza en \bar{x}_n

$$\text{EMV de } \mu : \hat{\mu} = \bar{X}_n$$

$$X_1, \cdots, X_n \text{ v.a. i.i.d. } X_i \sim \mathcal{N}(\mu, \sigma^2), \, f(x, \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \, e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$

$$L(\mu, \sigma^2; \mathbf{x}) \quad = \quad \prod_{i=1}^n f(x_i, \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$X_1, \cdots, X_n \text{ v.a. i.i.d. } X_i \sim \mathcal{N}(\mu, \sigma^2), f(x, \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$

$$L(\mu, \sigma^2; \mathbf{x}) = \prod_{i=1}^n f(x_i, \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$L(\mu, \sigma^2; \mathbf{x}) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$

$$X_1, \dots, X_n \text{ v.a. i.i.d. } X_i \sim \mathcal{N}(\mu, \sigma^2), f(x, \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$

$$L(\mu, \sigma^2; \mathbf{x}) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^n e^{-\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2}}$$

- Tomando logaritmo y resolviendo las ecuaciones

$$\frac{\partial \ell(\mu, \sigma^2; \mathbf{x})}{\partial \mu} = 0 \quad \text{y} \quad \frac{\partial \ell(\mu, \sigma^2; \mathbf{x})}{\partial \sigma^2} = 0$$

se obtiene que los EMV de μ y σ^2 son

$$\hat{\mu} = \bar{X}_n \quad \hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n}$$

Ejemplo $U(0, \theta)$: $f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{(0, \theta)}(x)$.

$$X_1 \dots X_n \sim \mathcal{U}(0, \theta).$$

$$f(x_1, \dots, x_n, \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}_{(0, \theta)}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathbb{I}_{(0, \theta)}(x_i)$$

Ejemplo $U(0, \theta)$: $f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{(0, \theta)}(x)$.

$$X_1 \dots X_n \sim \mathcal{U}(0, \theta).$$

$$f(x_1, \dots, x_n, \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}_{(0, \theta)}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathbb{I}_{(0, \theta)}(x_i)$$

$$= \begin{cases} \frac{1}{\theta^n} & \text{si } 0 < x_i < \theta \text{ para todo } i \\ 0 & \text{otro caso} \end{cases}$$

Ejemplo $U(0, \theta)$: $f(x, \theta) = \frac{1}{\theta} \mathcal{I}_{(0, \theta)}(x)$.

$$X_1 \dots X_n \sim \mathcal{U}(0, \theta).$$


$$f(x_1, \dots, x_n, \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}_{(0, \theta)}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathbb{I}_{(0, \theta)}(x_i)$$

$$= \begin{cases} \frac{1}{\theta^n} & \text{si } 0 < x_i < \theta \text{ para todo } i \\ 0 & \text{otro caso} \end{cases}$$

$$= \begin{cases} \frac{1}{\theta^n} & \text{si } \theta > \max(x_i) \\ 0 & \text{otro caso} \end{cases}$$

Estimador de máxima verosimilitud: Distribución Uniforme

Gráfico de la función de verosimilitud, $f(\mathbf{x}, \theta)$ correspondiente a $n = 8$ observaciones tales que $\max_{1 \leq i \leq n}(X_i) = 5$.



El E.M.V. de θ es

$$\hat{\theta}_n = \max_{1 \leq i \leq n} (X_i)$$

Propiedad de Invarianza de los EMV:

Sea $\hat{\theta}$ el EMV de θ y sea h una función inyectiva con dominio en el rango de valores posibles de θ , entonces el EMV de $h(\theta)$ es $h(\hat{\theta})$.
Por ejemplo, en el caso de una m.a. de una distribución $N(\mu, \sigma^2)$ hemos visto que el EMV de σ^2 es

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$$

entonces el EMV de σ es

$$\hat{\sigma} = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}}$$

pues la función $h(x) = \sqrt{x}$, $h: \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}$ es inyectiva.